Experimento 1: buscar la evidencia

Qué entra, por qué pasos pasa, qué sale y qué se concluye

La pregunta del experimento

> Sobre las **mismas 20 preguntas** y los **mismos 426 pasajes**: ¿qué buscador encuentra mejor el pasaje con la respuesta, y cuánto tarda?

Es la parte de **búsqueda** del RAG. Aquí todavía no hay LLM: solo se mide si el pasaje correcto aparece arriba en la lista. El LLM entra en el Experimento 2, que usa los 5 primeros pasajes de C.

Las condiciones que se comparan

	Condición	Qué hace	Idea
A	Densa (e5-small + FAISS)	Busca por **significado**: vectores parecidos	Entiende sinónimos, pero confunde códigos parecidos
B	A + BM25 + RRF	Agrega búsqueda por **palabras exactas** y junta las dos listas	Ayuda con códigos (006R01830)
C	B + Cross-Encoder	Un **juez** relee los 20 candidatos de B y los reordena	Más preciso, pero más lento
A0	Referencia de la PC2	Como A, pero con chunks de 180 palabras	Mide cuánto mejoró la unidad de búsqueda

Ojo: de A a B cambian **dos cosas a la vez** (BM25 y la fusión RRF), así que no se puede saber cuál de las dos produce cada cambio. De B a C solo cambia el reranker: es su efecto puro.

Lo que se deja fijo (para que la comparación sea justa)

Qué	Valor
Datos	426 pasajes y 20 preguntas con qrels, congelados con SHA-256
Unidad de búsqueda	pasaje + encabezado de su compra (A, B y C)
Modelo denso	intfloat/multilingual-e5-small (revisión fijada), prefijos 'query:' / 'passage:'
Reranker	cross-encoder/mmarco-mMiniLMv2-L12-H384-v1 (revisión fijada)
Candidatos	20 en todas las condiciones
BM25 / RRF	k1 = 1,5 · b = 0,75 · RRF k = 60
Máquina	misma CPU, 8 hilos, semilla 42, una llamada de calentamiento antes de medir

El flujo completo

Los pasos 2 y 3 se hacen **una sola vez**. El paso 4 se repite para cada pregunta.

1 ENTRADAS (archivos de data/)

corpus.jsonl
55 compras reales del SEACE
426 pasajes (frases)

consultas.jsonl
22 preguntas de auditor
se miden 20 (Q21 y Q22 no tienen respuesta)

qrels.json
respuesta correcta de cada pregunta
ej.: Q20 -> E12-P06

Antes de empezar, congelamiento.json compara huellas SHA-256: si algún archivo cambió, el experimento se detiene.

2 PREPARAR LAS UNIDADES (una sola vez)

Pasaje + encabezado de su compra = 1 unidad -> 426 textos

Cada frase lleva delante el título y la entidad de su compra, para saber de qué compra habla:

```
LP-ABR-2-2025-PNADP-1 - ADQUISICIÓN DE LICENCIA ANTIVIRUS KASPERSKY... | PROGRAMA NACIONAL DE APOYO...
Buena pro otorgada a BAFING S.A.C por S/ 363,270.00 (fecha 2025-11-21)...
```

3 INDEXAR (una sola vez)

Índice denso (por significado)
El modelo e5-small convierte cada texto en un vector de 384 números ('passage: ' + minúsculas, normalizado).
Los 426 vectores se guardan en FAISS (IndexFlatIP).

Índice de palabras (BM25)
Cada texto se parte en palabras (minúsculas, sin 'de', 'la', 'el'...).
BM25 recuerda en qué textos aparece cada palabra y cuáles son raras (pesan más).

A0 (referencia de la PC2): lo mismo que el índice denso, pero con 86 chunks de 180 palabras. Solo sirve para comparar.

4 BUSCAR (se repite para cada una de las 20 preguntas)

Pregunta (viene de consultas.jsonl)
Q20: ¿Qué empresa ganó la compra de licencias de antivirus para el Programa Juntos?

A · Denso
La pregunta se convierte en vector ('query: ') y FAISS devuelve los 20 pasajes con el vector más parecido.
Sale: top-20 ordenado por parecido (producto punto).

B · A + BM25 + RRF
BM25 arma su propio top-20 contando palabras que coinciden con la pregunta.
RRF junta las dos listas: cada pasaje suma 1/(60 + su posición) en cada lista. Ej.: 4º en A y 1º en BM25 -> 1/64 + 1/61 = 0,032.
Sale: nuevo top-20 fusionado.

C · B + Cross-Encoder (reranker)
Un segundo modelo lee juntos (pregunta, pasaje) para los 20 pasajes de B, les pone una nota y los reordena.
No trae pasajes nuevos: solo reordena los 20 de B. Sale: ranking final.

5 · EVALUAR (con qrels.json)
Se compara cada ranking con la respuesta correcta:
Recall@1/3/5 · MRR · nDCG@5 · latencia · bootstrap · tipo de fallo.

6 · SALIDAS (results/exp1/)
resumen, por_consulta, latencia, bootstrap, fallos (.csv) y rankings.jsonl.
El top-5 de C pasa al Experimento 2 (RAG).

El flujo paso a paso

Paso	Entra	Qué se hace	Sale
0. Verificar	corpus, consultas, qrels, referencias	Se recalculan las huellas SHA-256 y se comparan con congelamiento.json	OK, o se detiene si algo cambió
1. Preparar	corpus.jsonl (55 compras)	A cada pasaje se le pega el encabezado de su compra	426 textos
2a. Indexar denso	426 textos	e5-small convierte cada texto en un vector de 384 números	índice FAISS con 426 vectores
2b. Indexar BM25	426 textos	Se parten en palabras y se cuentan	índice de palabras
3. Buscar A	pregunta	Pregunta → vector → FAISS busca los 20 más parecidos	top-20 (A)
4. Buscar B	pregunta + top-20 de A	BM25 da su top-20; RRF junta ambas listas	top-20 (B)
5. Reordenar C	pregunta + top-20 de B	El Cross-Encoder puntúa los 20 pares (pregunta, pasaje)	top-20 reordenado (C)
6. Evaluar	rankings + qrels.json	Métricas por pregunta, promedio, bootstrap y tipo de fallo	CSV en results/exp1/
7. Entregar	ranking de C	Se guardan los rankings	el top-5 de C se usa en el Experimento 2

Ejemplo real 1: Q20, el reranker resuelve

Pregunta: ¿Qué empresa ganó la compra de licencias de antivirus para el Programa Juntos?
Respuesta correcta (qrels): `E12-P06`, "Buena pro otorgada a BAFING S.A.C por S/ 363,270.00"

Condición	Posición de E12-P06	Primeros 3 pasajes	Por qué
A	4º	E12-P07, E12-P05, E12-P01	Todos los pasajes de la compra se parecen; el denso no distingue cuál dice "ganó"
B	5º	E12-P07, E12-P01, E12-P02	BM25 no ayuda: la pregunta y la frase comparten pocas palabras
C	**1º**	**E12-P06**, E12-P05, E12-P07	El Cross-Encoder lee "¿qué empresa ganó?" junto a "Buena pro otorgada a…"

Ejemplo real 2: Q06, BM25 resuelve

Pregunta: ¿En qué proceso se compró el tóner Xerox con código de referencia 006R01830?
Respuesta correcta: `E49-P05` ("TÓNER… XEROX COD. REF. 006R01830 MAGENTA"). La misma compra tiene otros 4 tóneres con códigos casi iguales (006R01829, …).

Condición	Posición de E49-P05	Por qué
A	4º	Para el vector, los 5 tóneres son casi iguales (notas 0,873 · 0,871 · 0,871…)
B	**1º**	La palabra "006r01830" solo está en ese pasaje: BM25 la pesa mucho. RRF: 1/(60+4) + 1/(60+1) = 0,032, la más alta
C	**1º**	El reranker mantiene el acierto de B

Cómo se mide

Para cada pregunta se toma el ranking y se mira **en qué posición** aparece el pasaje correcto (qrels). Ejemplo con Q20: en A está 4º y en C está 1º.

Métrica	Qué significa	Q20 en A (4º)	Q20 en C (1º)
Recall@1	¿El correcto está en el 1er lugar? (fracción de correctos en el top-1)	0	1
Recall@3	¿Está entre los 3 primeros?	0	1
Recall@5	¿Está entre los 5 primeros? (lo que verá el LLM)	1	1
MRR	1 / posición del primer correcto (1º = 1; 2º = 0,5; 4º = 0,25)	0,25	1
nDCG@5	Premia que los correctos estén arriba dentro del top-5 (1 = perfecto)	0,43	1

Luego se **promedian las 20 preguntas**. Además se mide la **latencia** (milisegundos por pregunta, media y p95 = el 95 % de las preguntas tarda menos que eso).

¿La diferencia es real o suerte? Bootstrap pareado

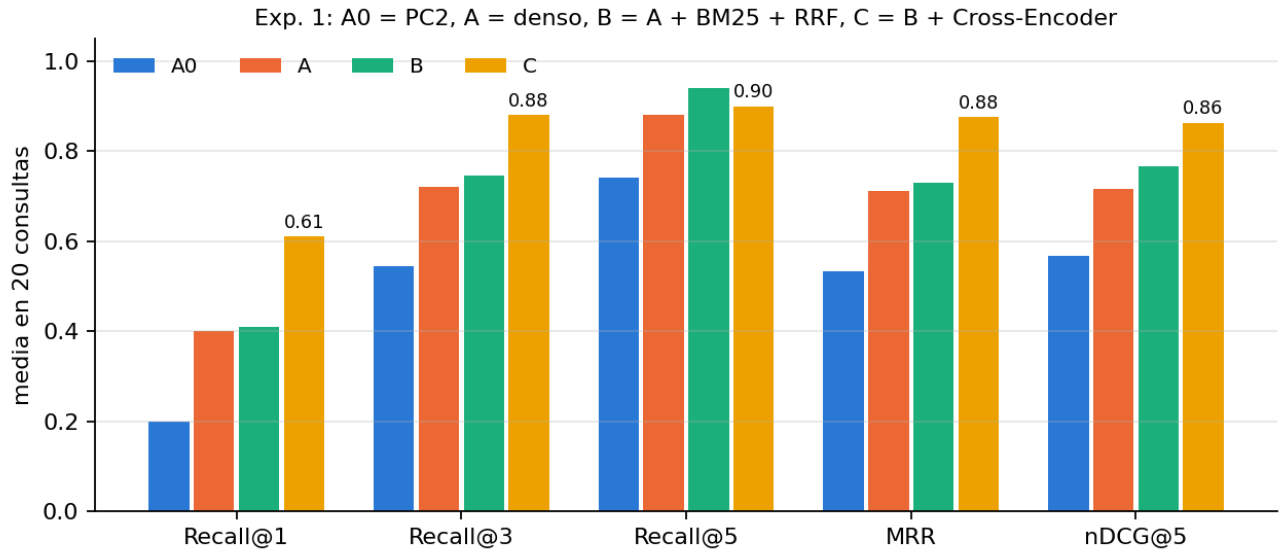
Con solo 20 preguntas, un promedio más alto puede ser casualidad. El bootstrap vuelve a sortear las 20 preguntas 5000 veces y calcula la diferencia entre dos condiciones cada vez. Con eso sale un intervalo de confianza del 95 %. **Si el intervalo incluye el 0, no se puede afirmar que una condición sea mejor que la otra.**

Tipo de fallo (taxonomía de la Semana 7)

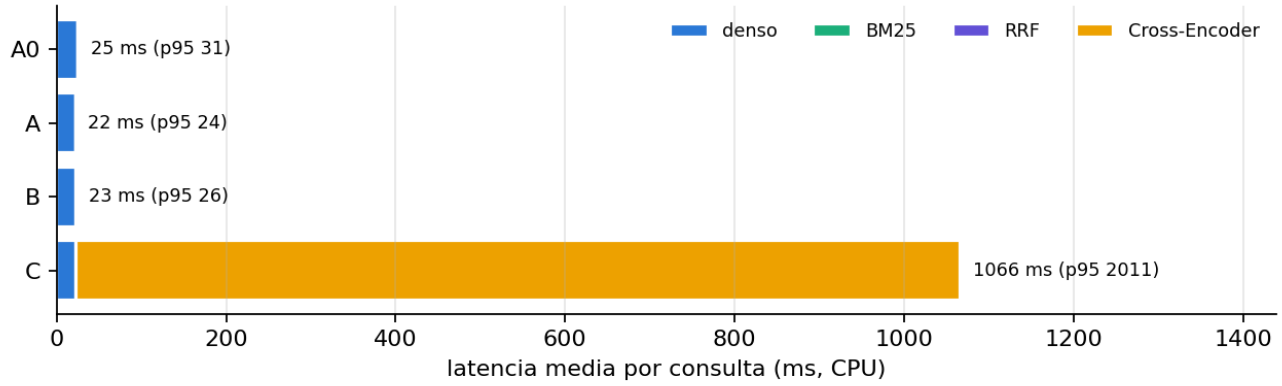
Tipo	Significa
RETRIEVAL_OK	Todos los pasajes correctos están en el top-3
PARTIAL_RECALL	Algunos correctos están en el top-3, pero no todos
RANKING_ERROR	Está entre los 20 candidatos, pero ninguno llega al top-3 (mal ordenado)
RETRIEVAL_MISS	No está ni entre los 20 candidatos (no lo encontró)

Resultados

Condición	Recall@1	Recall@3	Recall@5	MRR	nDCG@5	Latencia media	p95
A0 (PC2)	0,20	0,545	0,74	0,533	0,567	25 ms	31 ms
A · denso	0,40	0,72	0,88	0,712	0,717	22 ms	24 ms
B · + BM25 + RRF	0,41	0,745	**0,94**	0,731	0,765	23 ms	26 ms
C · + Cross-Encoder	**0,61**	**0,88**	0,90	**0,875**	**0,862**	1066 ms	2011 ms



Latencia por etapa: denso 22 ms · BM25 1 ms · RRF 0,05 ms · Cross-Encoder 1043 ms (20 pares por pregunta). C tarda ~46 veces más que B.



¿Las diferencias son reales? (bootstrap, IC 95 %)

Comparación	Recall@3	MRR	nDCG@5	¿Clara?
B − A	+0,025 [−0,125; 0,175]	+0,019 [−0,099; 0,148]	+0,049 [−0,028; 0,130]	No
C − B	+0,135 [−0,005; 0,295]	+0,144 [−0,008; 0,296]	+0,097 [−0,026; 0,209]	No (por poco)
C − A	+0,160 [0,020; 0,325]	+0,163 [0,025; 0,305]	+0,145 [0,028; 0,253]	**Sí**
A − A0	+0,175 [−0,025; 0,375]	+0,179 [0,051; 0,319]	+0,150 [0,034; 0,270]	Sí en MRR y nDCG

Tipos de fallo (20 preguntas)

Condición	RETRIEVAL_OK	PARTIAL_RECALL	RANKING_ERROR	RETRIEVAL_MISS
A0	10	2	7	1
A	12	5	3	0
B	13	4	2	1
C	**16**	3	**0**	1

Casos donde algo sale mal (resultados negativos)

Pregunta	Qué pasa
Q03 Adobe admitiendo equivalente	B tenía el ítem correcto 1º; C lo baja al 9º y prefiere otra compra de Adobe **sin** equivalente (el distractor). El reranker no entiende bien la negación.
Q13 adjudicado > 30 % sobre el valor	Falla en todas: hay que comparar números (132 % vs 120 %) y ningún buscador compara números. A lo deja 15º; B lo saca de los 20 y C ya no puede recuperarlo.
Q17 Office 365 del FONDEPES	RRF adelanta otra compra de Office 365 (INACAL) y empeora el ranking; C lo corrige a medias (2º).
Recall@5	C (0,90) queda por debajo de B (0,94): al reordenar, saca del top-5 pasajes que B tenía dentro (Q03, Q14).
A vs A0	Parte de la ventaja de A es de la medición: A0 se mide expandiendo sus chunks a ~100 pasajes, y la evidencia queda 5ª o 6ª aunque el chunk correcto esté 1º.

Conclusiones

#	Conclusión
1	**C es la mejor** en Recall@1, Recall@3, MRR y nDCG@5 (MRR 0,875), pero tarda ~1 s por pregunta en CPU (×46 frente a B).
2	Con 20 preguntas, **solo C − A es una diferencia clara**. C − B y B − A cruzan el cero: no se puede decir que una sea mejor.
3	**BM25 + RRF no mejora en promedio**: ayuda con códigos exactos (Q06), pero la fusión a veces adelanta un distractor (Q17).
4	**Cambiar la unidad** (pasaje + encabezado en vez de chunks de 180 palabras) subió el MRR en 0,18, aunque parte se debe a cómo se mide A0.
5	No se declara a C mejor en general: empeora Q03 y el Recall@5, y el benchmark es chico.

Limitaciones

20 preguntas no prueban generalización · las preguntas y los qrels son de los autores · el texto de los pasajes usa una plantilla fija (puede favorecer a BM25 y al denso) · una sola máquina y una sola corrida en CPU.

Qué pasa después

El **top-5 de C** (guardado en `results/exp1/rankings.jsonl`) es el contexto que recibe el LLM en el **Experimento 2**. Se eligió C porque es la que mejor ordena el principio de la lista.

Archivos de salida (results/exp1/)

Archivo	Qué guarda
resumen.csv	Promedio de cada métrica por condición

Archivo	Qué guarda
por_consulta.csv	Métricas, latencia y tipo de fallo de cada pregunta y condición
latencia.csv	Tiempo medio por etapa y p95
bootstrap.csv	Diferencias entre condiciones con su intervalo de confianza
fallos.csv	Conteo de tipos de fallo
rankings.jsonl	El ranking completo de cada pregunta en cada condición
manifiesto.json	Configuración, versiones de librerías y hashes del benchmark

Glosario rápido

Término	En simple
Pasaje	Una frase de una compra (ej. "Buena pro otorgada a..."). Hay 426.
Embedding / vector	Lista de 384 números que resume el significado de un texto; textos parecidos tienen vectores parecidos.
FAISS	Librería que guarda los vectores y encuentra rápido los más parecidos a la pregunta.
BM25	Búsqueda por palabras: puntúa más los textos que comparten palabras raras con la pregunta.
RRF	Forma de juntar dos rankings sumando 1/(60 + posición) de cada uno.
Cross-Encoder	Modelo que lee la pregunta y el pasaje juntos y les pone una nota de relevancia.
qrels	La hoja de respuestas: qué pasaje es el correcto para cada pregunta.
top-k	Los k primeros resultados de la lista.