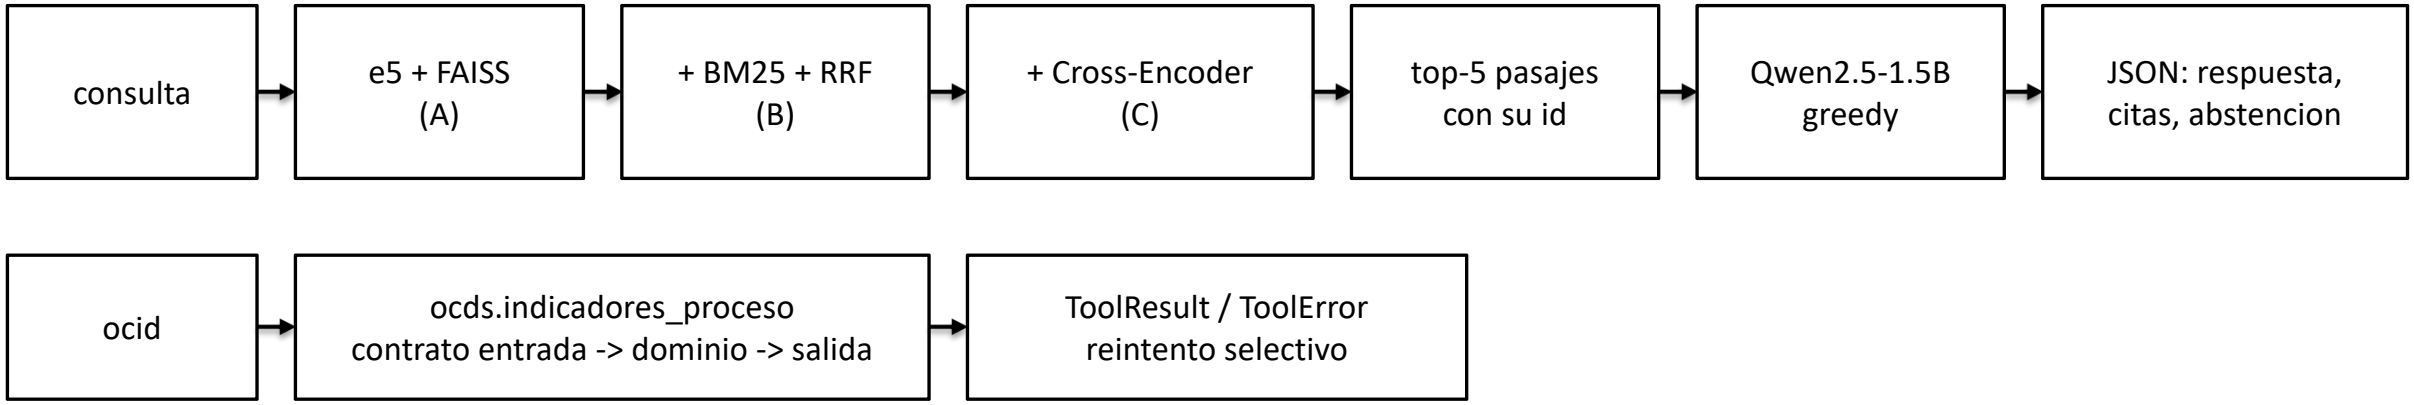
Examen Parcial - Tópicos de Ciencia de la Computación 1

Recuperación, RAG y contratos de herramientas sobre registros OCDS del SEACE

Problema y continuidad con la PC1 y la PC2

- Un requisito está direccionado cuando favorece a una marca, por ejemplo pidiéndola sin "o equivalente"
  - La evidencia está repartida en muchos procesos parecidos y una respuesta sin fuente no sirve
- PC1: Qwen2.5-0.5B clasifica un requerimiento OCDS en un JSON validado, pero no busca evidencia
- PC2: recuperador denso sobre 10 fichas, Recall@3 = 0,47
  - El chunk separaba la buena pro del ítem que la identifica, y "o equivalente" se perdía en el embedding
- EP: 55 procesos reales, 20 consultas con qrels, comparación A/B/C, RAG con citas y una herramienta con contratos
  - Corrección a la PC2: la unidad es un pasaje + el encabezado de su proceso (la config. de la PC2 queda como A0)
- Pregunta: ¿qué recuperación encuentra mejor la evidencia, cuánto cuesta, y con esa evidencia el LLM responde bien y sustentado?

Arquitectura y datos

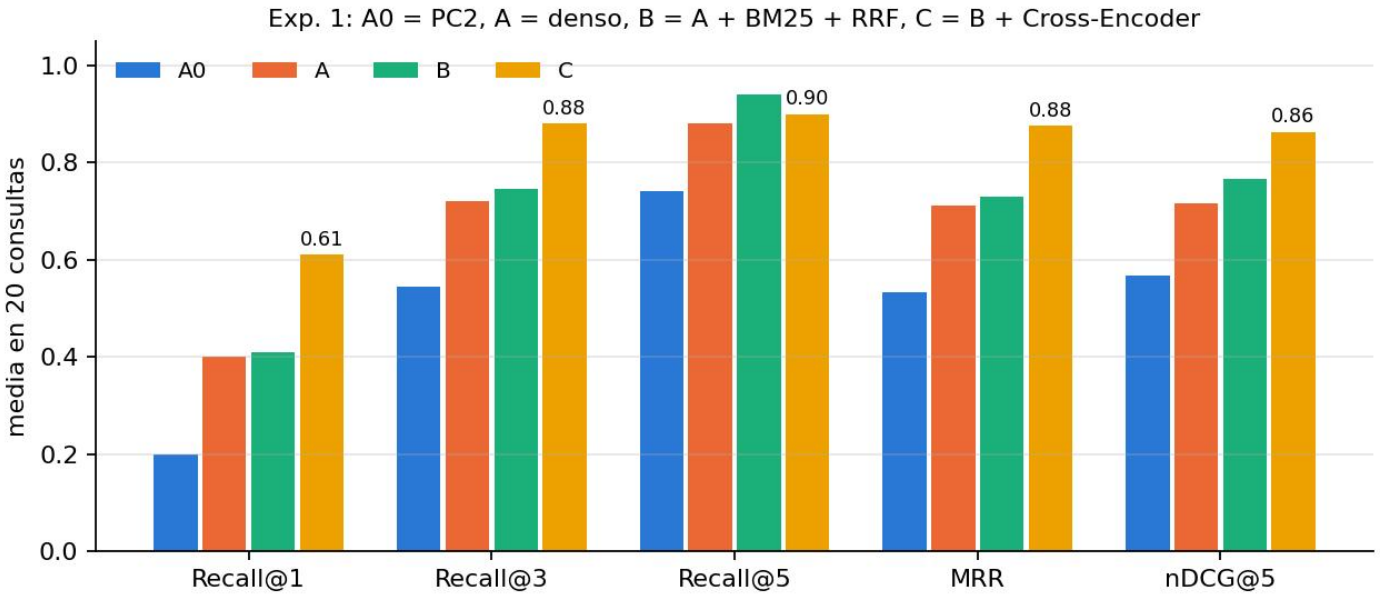


Datos	
Corpus	55 procesos reales del SEACE (OCDS), 426 pasajes
Pasajes	convocatoria, ítems, cronograma, documentos, postores, resultado, contrato
Consultas	22: 20 con qrels (11 difíciles, distractores reales) y 2 controles sin evidencia
qrels	anotados leyendo los pasajes y congelados con SHA-256 antes de correr (b623b36)
Modelos	e5-small, mMiniLM Cross-Encoder, Qwen2.5-1.5B; revisiones fijadas, CPU

Trazabilidad de las semanas 1 a 7

Semana	Recurso	Dónde se aplica	Evidencia / conclusión
1	Lectura 2, Cuaderno 1	bi-encoder (e5) vs Cross-Encoder (atención conjunta)	C gana MRR +0,16 sobre A, pero cuesta ~48 veces más
2	Lectura 3, Cuaderno 2, Lab 2	greedy y costo del contexto en el exp. 2	271 vs 943 tokens de prompt; 20 s vs 35 s
3	Cuaderno 3	JSON {respuesta, citas, abstencion}	24/24 JSON válidos, 4 incorrectas: formato ≠ corrección
4	Cuaderno 4, Lab 4	unidad de recuperación, FAISS IndexFlatIP	A − A0: MRR +0,18 [0,05; 0,32]
5	Cuaderno 5, Lectura 5	BM25, RRF k = 60, Cross-Encoder, RAG	Q06: rank 4 -> 1 con BM25; B ≈ A en promedio
6	Cuaderno 6, Lectura 6	contratos, ToolError, reintento, timeout	A 6/16, D 16/16 sin reintentos inútiles
7	Cuaderno 7, Lectura 7	Recall@k, MRR, nDCG, bootstrap, auditoría	solo C − A no cruza cero; citas auto ≠ manual

Experimento 1: recuperación densa, híbrida y con reranking

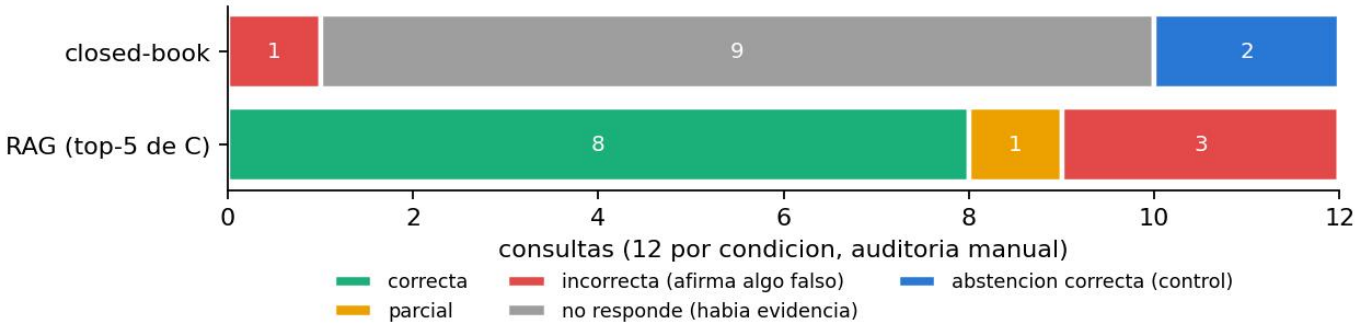


	Latencia media	p95
A0	25 ms	31 ms
A	22 ms	24 ms
B	23 ms	26 ms
C	1066 ms	2011 ms

Bootstrap (MRR)	Δ e IC 95 %
B − A	+0,02 [−0,10; 0,15]
C − B	+0,14 [−0,01; 0,30]
C − A	+0,16 [0,02; 0,31]

- Q06 (código 006R01830): rank 4 en A, rank 1 con BM25
- Q20, Q12: solo el Cross-Encoder pone la buena pro / los postores en el rank 1
- Q03: el reranker baja el ítem correcto al rank 9 y prefiere el distractor (Adobe sin equivalente)
- Q13 (> 30 % sobre el valor referencial) falla en todas: hay que comparar números
- Negativo: Recall@5 de C (0,90) < B (0,94); B − A y C − B cruzan cero

Experimento 2: closed-book vs RAG



Auditoría manual	Closed-book	RAG
Correctas / parciales	0 / 0	8 / 1
Abstención en controles	2/2	0/2
Faithfulness	0/1	16/19
Citas que sustentan	-	12/25
Citas en qrels (auto)	-	12/25

- Mismo Qwen2.5-1.5B, 12 preguntas fijadas y greedy; solo cambia el contexto (vacío vs top-5 de C)
- Q21 (sanción, sin evidencia): "el Tribunal impuso una sanción de S/ 184,500.00" citando la buena pro E01-P06
- Q22: inventa un plazo de "30 días"; Q15: dice que no aceptaba equivalentes y luego que sí
- Q12: respuesta correcta, pero cita E50-P01 en vez de E50-P05 (postores)
- Q04: la cita está en qrels pero no sustenta lo que dice: auto 12/25 y manual 12/25 no son las mismas citas

Experimento 3: herramienta ocds.indicadores_proceso

- Entrada: ocid (patrón SEACE) y tender_item_id (entero estricto); extra=forbid
- Dominio: el ocid existe, el ítem es del proceso, hay que elegir ítem si hay varios
- Salida: único postor, adjudicado / valor ref., "o equivalente" en objeto vs ítem; tipos y coherencia
- Se reintenta solo transient y timeout (solo lectura, 3 intentos, 100 ms por intento, deadline 300 ms)
    - No: validation, domain, output_contract, execution (reintentar da el mismo error)

Política (16 casos)	Cumplen	Entradas inválidas ejecutadas	Salidas inválidas aceptadas	Intentos	Reintentos inútiles
A sin contratos	6/16	3	1	16	0
B contratos	14/16	0	0	13	0
C reintenta todo	16/16	0	0	29	10
D reintento selectivo	16/16	0	0	19	0

- A acepta un argumento inventado y devuelve ok; también deja pasar n_postores = −1
- 22 pruebas con pytest: válida, inválida, dominio, transitorio, timeout, error interno, salida rota

Resultados, errores y conclusiones

- La unidad de recuperación importó más que el método: pasaje + encabezado subió el MRR en 0,18 frente a la PC2
- BM25 + RRF no mejora en promedio; ayuda con códigos exactos y empeora cuando la fusión adelanta un distractor
- El Cross-Encoder mejora el inicio del ranking (Recall@1 0,41 -> 0,61) a ~1 s por consulta; contra B no es concluyente
- RAG: 8 correctas y 1 parcial de 10, pero 0/2 abstenciones y 13 de 25 citas no sustentan nada
    - Una respuesta citada no es una respuesta verificada
- La herramienta con contratos evita ejecuciones inválidas silenciosas; reintentar todo gasta sin ganar
- Limitaciones: 20 consultas, qrels y auditoría nuestros, sin las bases en PDF, un solo LLM pequeño, fallos simulados